Theoretische Informatik III (T3INF2002)

Formale Sprachen und Automaten | Einführung Compilerbau

Vorlesung im Wintersemester 2022/23

Kurzvorstellung

Aktuelle Position: Wissenschaftliche Mitarbeiterin und Doktorandin, Karlsruher Institut für Technologie (KIT)

Forschungsinteresse:

- Menschen-zentrierte KI-Systeme
- Repräsentation und Verarbeitung ethischer und rechtlicher Aspekte in intelligenten, komplexen Systemen

Berufserfahrung:

Verschiedene Projekte als DWH/BI Consultant und Leiterin Business Intelligence

Studium:

- Master of Science in Informatik
- Bachelor of Science Wirtschaftsinformatik

Organisatorisches I

- Vorlesung Formale Sprachen und Compilerbau
 - Exkurse mit praktischem Bezug
 - Formale Sprachen: 48h
 - Compilerbau: 24h
- Aufteilung Vorlesung / Übung
 - Übungen finden ab dem 10. Oktober 2022 statt
 - Zeiten Vorlesung / Übung werden noch bekanntgegeben
 - Unterlagen werden nach der Vorlesung/Übung bereitgestellt

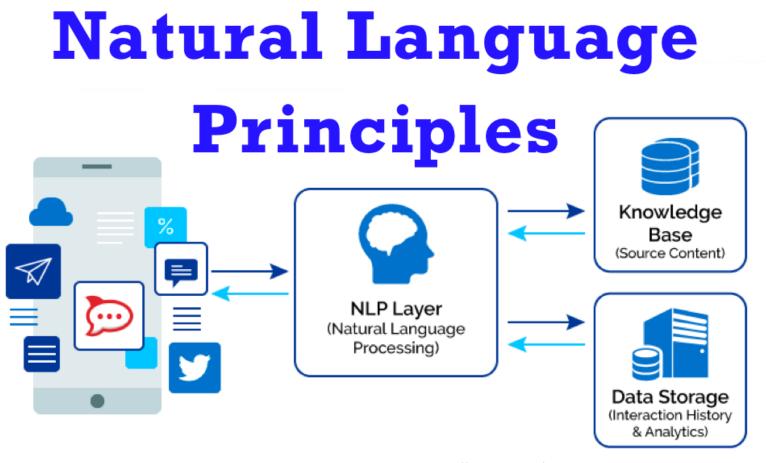
Organisatorisches II

- Bereitstellung eines eigenen Moodle-Raums
 - Aktuell noch im Aufbau
- Prüfungsleistung Klausur am Semesterende
 - Aufgaben aus beiden Themenbereichen
 - (Bonuspunkte für Prüfungsleistung bei Bearbeitung und Abgabe der Übungen) -> noch in Absprache

Formale Sprachen und Automaten

- Grammatiken
- Sprachklassen (Chomsky-Hierarchie)
- Erkennende Automaten Reguläre Sprachen
- Reguläre Grammatiken
- Endliche Automaten
- Nicht deterministische / deterministische endliche Automaten
- Kontextfreie Sprachen
- Kontextfreie Grammatiken
- Verfahren zur Analyse von kontextfreien Grammatiken (CYK)
- Kellerautomaten
- Zusammenhang Turingmaschine, formale Sprachen vom Chomsky Typ 0 und Entscheidbarkeit

Exkurs: Natural Language Processing (NLP)



https://chatbotslife.com/natural-language-principles-65e88e20b94

Conversational Interface...Chatbots, Sprachassistenten, etc.

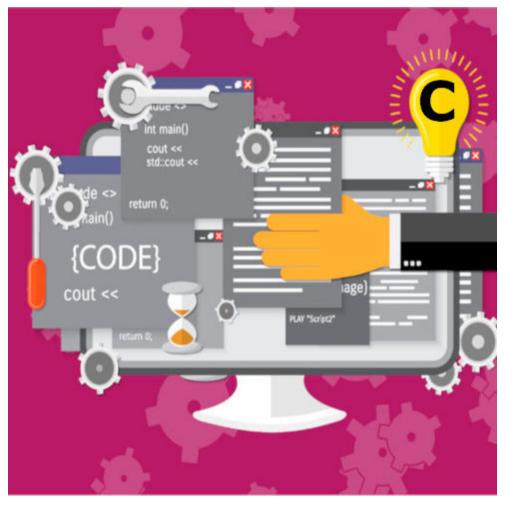


https://aliz.ai/en/blog/natural-language-processing-a-short-introduction-to-get-you-started/

Einführung Compilerbau

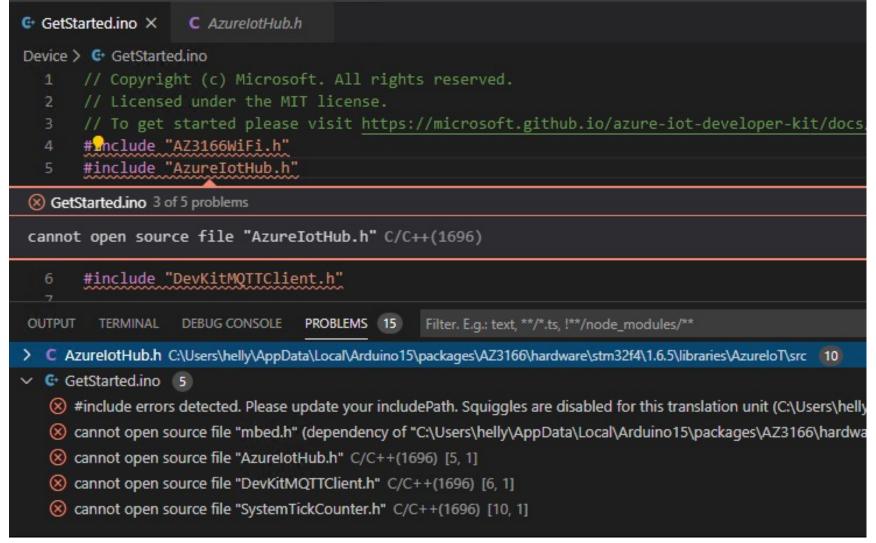
- Phasen des Compilers
- Lexikalische Analyse (Scanner)
- Syntaktische Analyse (Parser)
- Syntaxgesteuerte Übersetzung
- Syntaxanalyse-Verfahren
- Semantische Analyse: Typüberprüfung

Exkurs: Programmierung



https://www.embedded-software-engineering.de/c-programmieren-wie-arbeitet-ein-c-compiler-a-740687/

Compiler in Entwicklungsumgebungen



Formale Sprachen I

Sprachen, die zur computergerechten Darstellung von Information und der Festlegung einer automatisieren Verarbeitung von Daten verwendet werden, müssen hohe Anforderungen an die Präzision und Ausdrucksweise erfüllen.

-> Syntax und Semantik solcher Sprachen werden daher präzise festgelegt.

Ziele:

Formulierung von Algorithmen in eindeutiger und für Computer verständlicher Weise.

Mittel:

Formalismen, die gewisse Ähnlichkeiten mit gesprochenen Sprachen haben, sich aber in Bezug auf Zweckmäßigkeit und Eindeutigkeit von gesprochenen Sprachen abgrenzen.

Formale Sprachen II

Gesprochene Sprache hat u. a.

- Formalen Aufbau (Grammatik, d.h. Regeln)
- Bedeutung (Semantik)
 - → auch bei formalen Sprachen

"kleine" grammatisch korrekte Unterschiede können zu großen Bedeutungsunterschieden führen; auch jenseits von Gegenseitigkeit

Bsp.: Der Weg ist das Ziel. Weg ist das Ziel.

→ auch in formalen Sprachen möglich

Formale Sprachen III

Formale Sprachen vs. gesprochene Sprachen

Zeichen aus Alphabet

.

Buchstaben aus Alphabet

Wörter

Wörter

Ausdrücke, Anweisungen,

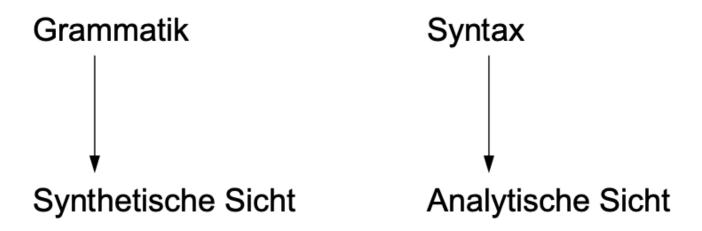
Sätze

Wörter, (Sätze)

Grammatiken

Um mit Sprachen, die im Allgemeinen unendliche Objekte sind, algorithmisch umgehen zu können, benötigt man endliche Beschreibungsmöglichkeiten für Sprachen.

-> Dazu dienen sowohl Grammatiken als auch Automaten.



Formale Grammatiken

Formalen Grammatik

- Lassen sich ausgehend von einem Startsymbol Produktionsregeln aus einer Regelmenge anwenden, die aus dem Startsymbol neue Zeichenfolgen (Wörter) erzeugen, welche wiederum weiter ersetzt werden können.
- Diesen Vorgang nennt man auch Ableitung.

Vokabular

- Grammatik, bestehend aus der disjunkten Vereinigung eines Alphabets von Terminalsymbolen mit einer Menge von Nichtterminalsymbolen, gibt dabei vor, welche Symbole dafür verwendet werden können.
- Menge der Terminalsymbole definiert, aus welchen Zeichen Wörter bestehen, die nicht weiter abgeleitet werden können.
- Wörter ergeben zusammengenommen die von der Grammatik beschriebene formale Sprache.
- Startsymbol muss dagegen ein Nichtterminalsymbol sein.
- Zusätzliche Nichtterminalsymbole erlauben differenziertere Regeln.

Sprachklassen (Chomsky-Hierarchie) I

Grammatiken sind mächtige Werkzeuge, die ganz verschiedenartige Sprachen erzeugen können.

- Man kann an der Grammatik selbst vor allem an den Regeln viele Eigenschaften der zugehörigen Sprache ablesen.
- Klassifizierung von Grammatiken nach der Komplexität ihrer Regeln führt zu einer Klassifizierung der formalen Sprachen selbst.

Bekanntestes Schema für eine solche Klassifizierung ist die Chomsky-Hierarchie.

• Sie ist benannt nach dem amerikanischen Linguisten Noam Chomsky.

Die Chomsky-Hierarchie hat vier Stufen:

- Typ 0 bis Typ 3.
- Je höher der Typ, desto eingeschränkter sind dabei die Regeln.
- Man nennt eine formale Sprache ebenfalls vom Typ n, wenn sie von einer Typ-n-Grammatik erzeugt wird.

Sprachklassen (Chomsky-Hierarchie) II

- Die in der Praxis auftretenden formalen Sprachen, wie beispielsweise Programmiersprachen, besitzen eine einfache Struktur.
- Sie können nach ihrer Komplexität in eine der bekannten Sprachklassen der Chomsky-Hierarchie eingeteilt werden.
- Diese sind, nach ihrer Mächtigkeit aufsteigend geordnet, die regulären Sprachen, (Typ 3), die kontextfreien Sprachen (Typ 2), die kontextsensitiven Sprachen (Typ 1) und die rekursiv aufzählbaren Sprachen (Typ 0).

Reguläre Sprachen können von endlichen Automaten, kontextfreie Sprachen von (nichtdeterministischen) Kellerautomaten, kontextsensitive Sprachen von linear beschränkten Turingmaschinen und rekursiv aufzählbare Sprachen von allgemeinen Turingmaschinen erkannt werden.

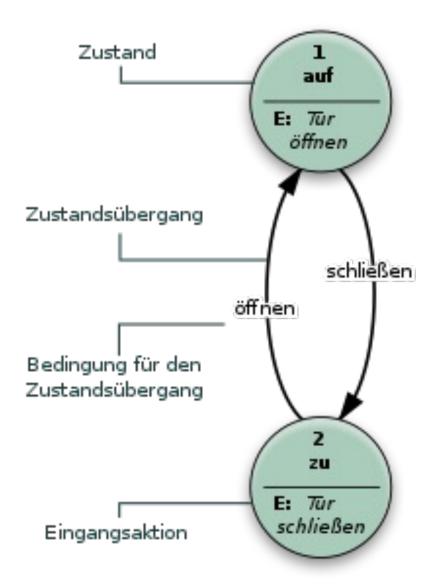
Endliche Automaten I

- Ein **endlicher Automat** (**EA**) ist ein Modell eines Verhaltens, bestehend aus *Zuständen*, *Zustandsübergängen* und *Aktionen*.
- Ein Automat heißt endlich, wenn die Menge der Zustände, die er annehmen kann, endlich ist.
- Ein endlicher Automat ist ein Spezialfall aus der Menge der Automaten.

Zustand auf E: Tur öffnen Zustandsübergang schließen öffnen Bedingung für den Zustandsübergang zu E: Tur schließen Eingangsaktion

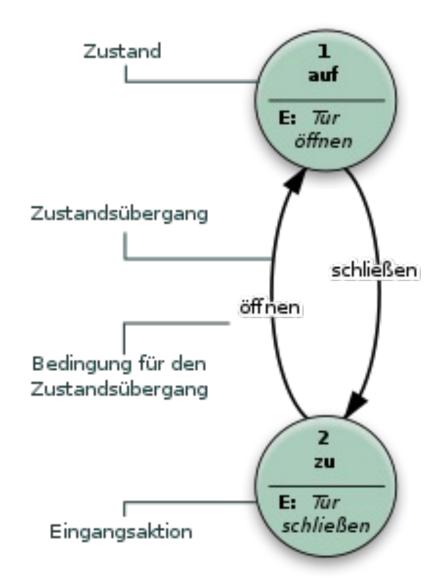
Endliche Automaten II

- Ein Zustand kann Information über die Vergangenheit beinhalten, da das System ihn auf dessen bisherigem Weg erreicht hat.
- D. h., er reflektiert die Änderungen der Eingabe seit dem Systemstart bis zum aktuellen Zeitpunkt.
- Ein Zustandsübergang ist ein Übergang aus dem aktuellen Zustand in einen neuen (anderen) Zustand.
- Zu diesem Übergang kommt es, wenn die angegebenen logischen Bedingungen/"Eingaben" vorliegen, die erfüllt sein müssen, um den Übergang zu ermöglichen.



Endliche Automaten III

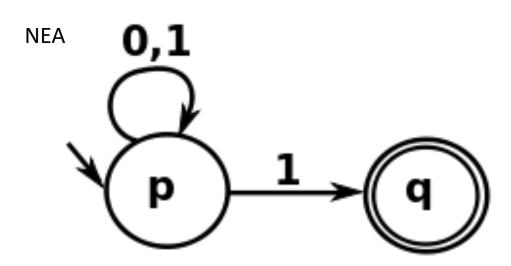
- Eine Aktion ist die "Ausgabe" des EA, die in einer bestimmten Situation erfolgt. Es gibt vier Typen von Aktionen:
 - Eingangsaktion: Aktion wird ausgeführt/ausgegeben beim Eintreten in einen Zustand.
 - Ausgangsaktion: Aktion wird beim Verlassen eines Zustandes generiert.
 - Eingabeaktion: Aktion wird abhängig vom aktuellen Zustand und der Eingabe generiert.
 - Übergangsaktion: Aktion wird abhängig/während eines Zustandsübergangs ausgeführt.



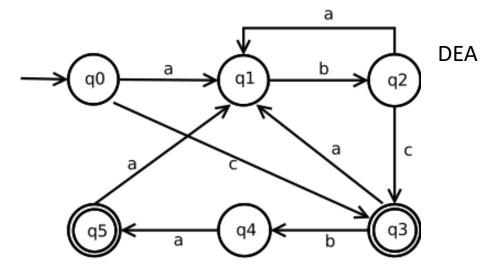
Nicht deterministische / deterministische endliche Automaten

Weitere Klassifizierung der EA wird durch die Unterscheidung zwischen deterministischen (DEA) und nichtdeterministischen (NEA) Automaten gemacht.

In den deterministischen Automaten existiert für jeden Zustand genau ein Übergang für jede mögliche Eingabe. Bei den nicht-deterministischen Automaten kann es keinen oder auch mehr als einen Übergang für die mögliche Eingabe geben.



https://de.wikipedia.org/wiki/Nichtdeterministischer endlicher Automat#/media/Datei:NFASimpleExample.svg



https://de.wikipedia.org/wiki/Deterministischer endlicher Automat#/media/Datei:Regexp-dfa.svg

Kontextfreie Sprachen

- Wird von der kontextfreien Grammatik erzeugt und wird entsprechend auch durch sie nachgewiesen.
- Diese werden in der Informatik hauptsächlich benötigt, da sie im Gegensatz zu regulären Grammatiken auch Klammerstrukturen zulassen.
- Der Ausdruck einer kontextfreien Sprache muss deshalb den Regeln der Grammatik entsprechen. Das bedeutet, dass eine kontextfreie Sprache auch wortwörtlich vom Kontext unabhängig ist.
- Kontextfreie Sprachen sind Typ-2-Sprachen der Sprachklasse der Chomsky-Hierarchie. Dabei besitzt eine kontextfreie Sprache Klasse die reguläre Sprache vom Typ 3 und wir dabei gleichzeitig von der kontextsensitiven Sprache vom Typ 1 umfasst.
- Dabei besitzt die Kontextfreie Sprache die folgenden Eigenschaften, wenn ihre Klasse als abgeschlossen gilt:
 - Vereinigung
 - Verkettung
 - Spiegelungen
 - Homomorphismen
 - Schnitt mit regulären Sprachen

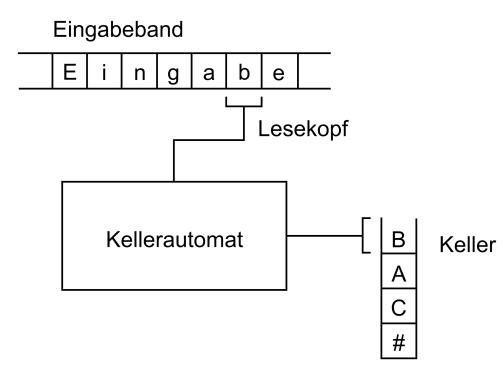
Eine kontextfreie Sprache gilt als nicht abgeschlossen.

Kontextfreie Grammatiken

- Beim Ableiten in Typ-1-Grammatiken muss man immer aufpassen, dass das Nichtterminal auch im richtigen Kontext steht.
- Das Erzeugen von Sätzen ist viel leichter, wenn die Grammatik kontext**frei** ist.
- Die kontextfreien Sprachen sind genau diejenigen, die von nichtdeterministischen Kellerautomaten (NDAs) akzeptiert werden.
- Hier weiß man bereits, dass deterministische Automaten nicht ausreichen. Im Bezug auf Grammatiken ergibt der Begriff *kontextfrei* viel mehr Sinn als bei den NDAs.

Kellerautomaten I

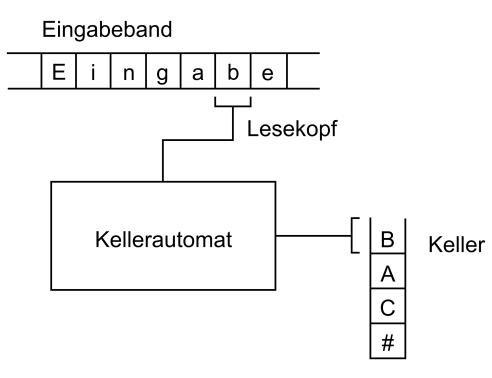
- Dient dazu, zu klären, ob eine Eingabe (d. h. ein Wort aus null, einem oder mehreren Zeichen) zu einer bestimmten formalen Sprache (d. h. einer Menge von Wörtern) gehört.
- Der Automat arbeitet das Eingabewort Schritt für Schritt von links nach rechts ab und kann dabei eine Reihe von Zuständen annehmen.



https://de.wikipedia.org/wiki/Kellerautomat#/media/Datei:Kellerautomat.svg

Kellerautomaten II

- Zu Anfang ist er der Automat im Startzustand.
- Normalerweise wird in jedem Verarbeitungsschritt ein Zeichen aus der Eingabe gelesen.
- Außerdem wird in jedem Verarbeitungsschritt das oberste Zeichen vom Keller gelesen, d. h. entfernt.
- Abhängig vom aktuellen Zustand, dem gerade gelesenen Eingabezeichen und dem gerade gelesenen Kellerzeichen geht der Automat in einen neuen Zustand über und legt anstelle des entfernten Kellerzeichens ein neues Wort auf dem Keller ab.
- Wenn die gesamte Eingabe gelesen wurde und der Keller leer ist, gehört die Eingabe zur vom Automaten erkannten Sprache.



https://de.wikipedia.org/wiki/Kellerautomat#/media/Datei:Kellerautomat.svg



Programmiersprache - Was ist das?

Formale Sprache, die zur Beschreibung von Berechnungen in Computern verwendet wird:

- Wichtig:
 - Sprache für menschlichen Leser verständlich
 - effizient implementierbar
- Sprache hat Syntax (vgl. Grammatiken) und Semantik (Bedeutung, Wirkung)

Programm = Daten + Algorithmus

Herausforderungen

— Sprachen, Dialekte, Versionen

... und das Hauptproblem der Vielfalt: Portabilität

— Klassifikation:

Wie kann eine Ordnung in die Vielfalt gebracht werden?

— Klassifikation ...

... nach Anwendungsgebieten

... nach der Historie

... nach Programmiersprachengenerationen

... nach Programmierparadigmen

Quelltext / Quellcode

Quelltext / Quellcode (1)

```
2 // Quellcodebeispiel in C++
4 #include <cstdlib>
5 #include <iostream>
7 using namespace std;
9 int main(int argc, char *argv[])
10 {
11
      int alter; // Variable vom Typ Integer
12
13
      cout << "Wie alt bist du?";
14
      cin >> alter;
15
      cout << "Du bist " << alter << " Jahre alt" << endl;
16
      getc();
17
      return 0;
18 }
19
```

https://de.wikipedia.org/wiki/Programmiersprache#/media/Datei:Quellcodebeispiel C++.png



Python

```
import os
 2 from lxml import etree
 3 from io import StringIO
    searchdir='/Path/To/ClassFiles'
 6 os.chdir(searchdir)
    print('Checking', os.getcwd())
    ext_list = ['html','css','js','php']
10 exclude_dirs = ['images']
11
12 for dirpath, dirnames, filenames in os.walk('.'):
        dirnames[:] = [d for d in dirnames if d not in exclude_dirs]
14
        filtered_filenames = [fname for fname in filenames if fname.split('.')[-1] in ext_lis
15
16
        for fname in filtered filenames:
17
            filepath = dirpath + '/' + fname
18
19
                with open(filepath) as f:
20
                    xml_to_check = f.read()
21
                    if xml_to_check[0:4] != '<cw:':</pre>
22
                        #print('Not XML:', filepath)
23
                        continue
24
                    # parse xml
26
                        doc = etree.parse(StringIO(xml to check))
                        #print('XML well formed, syntax ok.', filepath)
29
                    # check for file IO error
30
                    except IOError:
31
                        print('Invalid File:', filepath)
32
            except Exception as e:
                print('ERROR', filepath, e)
```

 $https://www.itmagazine.ch/imgserver/artikel/Illustrationen/2019/mid/Python_Code.png_190108_140119.jpg$

Quelltext / Quellcode (2)

Gemeinsamkeiten von Programmiersprachen

- Befehle: Anweisungen sind die Basis aller Anwendungen. Hiermit beschreibt der Programmierer, was das Programm tut. Befehle können z. B. bestimmte Rechenschritte auslösen oder einen Text anzeigen lassen.
- Variablen: Variablen sind Leerstellen (Platzhalter), die mit Informationen gefüllt werden können. Auf diese referiert man innerhalb des Quellcodes immer wieder mit einer zu vergebenden Bezeichnung (Variablenname).
- Vergleiche: Programme beinhalten Abfragen, die nach einem "Wenn-Dann-Schema" (also nach dem Prinzip der Aussagenlogik) funktionieren. Wenn ein bestimmter Wahrheitswert eintritt, wird ein Ereignis ausgelöst, ansonsten ein anderes.

Quelltext / Quellcode (3)

Gemeinsamkeiten von Programmiersprachen

- Schleifen: Abfragen können auch Grundlage für Schleifen im Quelltext sein. Ein Befehl wird so lange wiederholt, bis ein bestimmter Wert erreicht ist. Erst dann verlässt das Programm die Schleife und führt den restlichen Code aus.
- Kommentare: In allen g\u00e4ngigen Programmiersprachen kann man Zeilen innerhalb des Codes auskommentieren. Damit ist es m\u00f6glich, Text in den Quellcode zu schreiben, der nicht vom Programm ber\u00fccksichtigt werden soll. Man tr\u00e4gt z. B. Kommentare in den Quelltext ein, um Teile des Codes nachvollziehen und dokumentieren zu k\u00f6nnen.

Syntax

Syntax

- Programmiersprachen sind, wie auch natürliche Sprachen, nach definierten Regeln aufgebaut.
- Regeln legen fest, welche Zeichen verwendet werden dürfen, wie die Zeichen angeordnet sein müssen und welche Bedeutung bestimmte Zeichenfolgen haben.
 - Die Syntax einer Sprache bestimmt den Aufbau der Sätze.
 - Auf Programmiersprachen bezogen legt die Syntax z. B. fest, wie Anweisungen aufgebaut sind.

- Die Syntax einer Sprache kann mithilfe von Syntaxdiagrammen oder der Backus-Naur-Form (BNF) dargestellt werden.
 - In Syntaxdiagrammen wird die Grammatik einer Sprache grafisch dargestellt und ist dadurch leichter lesbar.
 - Die Backus-Naur-Form (BNF) verwendet eine textuelle Darstellung der Syntax und ist dadurch mit jedem Texteditor zu erfassen.
 - In Sprachbeschreibungen wird häufig die erweiterte Backus-Naur-Form (EBNF) verwendet, die im Vergleich zur BNF mehr Möglichkeiten bietet.

2022

Syntaxdiagramme

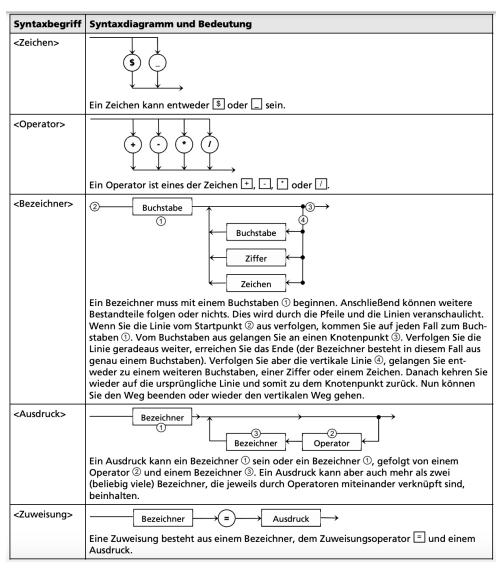
Die Syntaxdiagramme einer Sprache sind sehr umfangreich, da alle Konstrukte einer Sprache beschrieben werden.

-> Das Beispiel zeigt, wie ein numerischer Ausdruck einer Sprache dargestellt werden kann.

Syntaxbegriff	Syntaxdiagramm und Bedeutung
<ziffer></ziffer>	0 1 2 3 4 5 6 7 8 9
	Eine Ziffer kann ein Wert von 0 bis 9 sein.
<buchstabe></buchstabe>	a b c z A B C z
	Ein Buchstabe kann jeder kleine und große Buchstabe des Alphabets sein.

Syntaxdiagramme

Das Beispiel bezieht sich auf keine spezielle Sprache, sondern soll das Darstellungsprinzip verdeutlichen.



Programmierung Grundlagen, Tina Wegener, Ralph Steyer 2. Ausgabe, 1. Aktualisierung, April 2014

Beispiel: Syntax

For-Schleife, die die natürlichen Zahlen von 1 bis 10 ausgeben soll

https://mein-javablog.de/lexikalik-syntax-und-semantik-in-programmiersprachen/

-> Der Ausdruck ist lexikalisch und syntaktisch richtig, aber semantisch falsch.

Semantik

Semontik

Die Semantik erklärt die Bedeutung der Sätze. Auf Programmiersprachen bezogen wird durch die Semantik z. B. beschrieben, was eine Anweisung bedeutet.

Zweck einer Semantik:

- Formale eindeutige Beschreibung des Verhaltens eines Programms bzw. formale Beschreibung der Wirkung als Funktion
- Basis für korrekte Optimierungen, Programmtransformationen
- Basis für Programm-Verifikationen

Die Semantik beschäftigt sich damit, ob ein Satz oder eine Programmstruktur überhaupt Sinn ergibt.

Beispiel: Semantik

For-Schleife, die die natürlichen Zahlen von 1 bis 10 ausgeben soll

```
public class Semantik {
       public static void main(String[] args) {
               // For-Schleife soll von 1 bis 10 zählen
               for (int i = -5; i < 0; i++) {
                       System.out.println(i);
                                                 sematisch aber falsch.
```

https://mein-javablog.de/lexikalik-syntax-und-semantik-in-programmiersprachen/

Die for-Schleife ist lexikalisch und syntaktisch korrekt.

Aber der Schleifenzähler startet bei –5 und endet bei 0. Somit wird die Schleife abbrechen, bevor sie bei eins ankommt.

-> Das bedeutet, dass die Zahlen 1 bis 10 niemals gezählt werden.

Befehlssatz

Befehlssatz (1)

- Befehlssatz ist die Menge aller Instruktionen, die ein Mikroprozessor ausführen kann.
 - Er ist ein wichtiges Kriterium für die Leistungsfähigkeit eines Mikroprozessors.
- Ein Befehlssatz lässt sich in...
 - arithmetische und logische Befehle,
 - in Sprungbefehle,
 - Transferbefehle,
 - Inkrementierungs- und Dekrementierungsbefehle,
 - Ein- und Ausgabebefehle und Spezialbefehle untergliedern.

Arithmetische Operationen		
ADD SUB MUL AND	Addition von Operanden Subtraktion von Operanden Multiplikation von Operanden Logische AND-Operation	
Vergleichsoperationen		
EQ GT LT GEQ	Tested ganzahlige Operanden Ermittelt den größeren Operanden Ermittelt den kleineren Operanden Ob ein Operand größer/gleich ist	
Steuerungsoperationen		
JMP BLT	Setzen des Programmzählers auf die nächste Anweisung Setzen des ProgrZählers auf den ersten Operanden, wenn der zweite	

Befehlssatz (2)

Der Befehlssatz besteht aus einzelnen Befehlen, über die eine Software Anweisungen an den Prozessor übergibt.

- Zu den arithmetischen und logischen Befehlen z\u00e4hlen alle Befehle, die der Datenmanipulation dienen wie die Addition, Subtraktion, Multiplikation und Division sowie die logischen Verkn\u00fcpfungen mittels AND-Gatter, OR-Gatter und XOR.
- Zu den **Transferbefehlen** gehören alle Anweisungen, um Daten von einem Register in ein anderes zu transportieren oder kopieren.
- Die **Sprungbefehle** werden für Verzweigung von Programmen und den Aufruf von Unterprogrammen und Interrupts benutzt, die an einer anderen im Sprungbefehl angegebenen Stelle fortgesetzt werden sollen.
- Unterscheidung von normalen und ausführlichen Befehlssätzen, den Complex Instruction
 Set Computer (CISC), solchen mit reduzierten Instruktionen, den Reduced Instruction Set Computer
 (RISC) und solchen mit virtuellem Befehlssatz, den Virtual Instruction Set Computing (VISC).

Befehlssatz (3)

Was ist der Nutzen von Befehlssätzen?

— Antwort: Leistungssteigerung. Die Voraussetzung ist, dass die Software den Befehlssatz unterstützt. Außerdem wirkt sich die Leistungssteigerung in der Regel nur bei rechenintensiven Programmen aus.

Welcher Prozessor unterstützt welche Befehlssätze?

— Ein Prozessor unterstützt nicht alle Befehlssätze. Vor allem alte Prozessoren unterstützen kein bis wenige erweiterte Befehlssätze.